

06/03

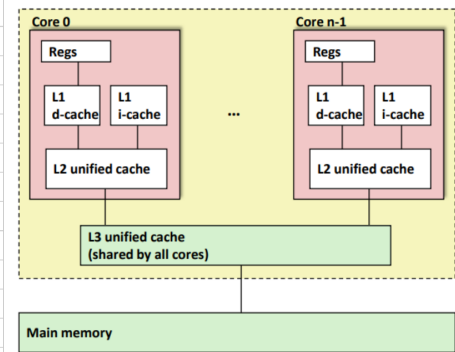
Thread-Level Parallelism

- Parallel Computing Hardware
 - Multi-core: Multiple separate processors on single chip
 - Hyperthreading: Efficient execution of multiple threads on single core
- Consistency Models
 - What happens when multiple threads are reading & writing shared state

Exploiting parallel execution

- 현재까지 우리는 I/O delay 때문에 thread를 써왔음.
- 224 Multi-core/Hyperthreaded CPU는 다른 기회 제공
- ↳ Thread 위에 work를 분배함으로써 실제로 parallel execution이 일어나게 할 수 있다. (자율적인 분배 행위가 일어남)
 - ex) 다양한 APP
 - ↳ Big Task를 Sub Task로 쪼개서 Threads에게 분배

Typical Multicore Processor



- L1과 L2는 'Private Cache'로 각 Core에 대해 하나씩 존재
- 반면 L3는 모든 Core가 공유
- L1 Cache는 Data와 Instruction Cache로 구분
- L2, L3 Cache는 Unified Cache

ex01) Parallel Summation

0부터 n-1까지 더하기.

$$\text{총 합은 } 0 + 1 + \dots + (n-1) = \frac{n(n-1)}{2} = (n-1)n/2$$

이것을 t개의 range로 나눔. → 각 partition (range)에는 $\lfloor n/t \rfloor$ 만큼 수가 들어있어.

" " 은 thread가 각각 담당

+) 편의상 n이 t의 배수라고 하겠음.

+) 분교재 machine

↳ 8 cores → 2x hyperthreading, 마치 16개의 core가 있는 수준의 성능

First attempt: psum-mutex : thread들이 각각의 분할량을 전역변수에 업데이트 + semaphore를 통한 synchronization

```
void *sum_mutex(void *vargp); /* Thread routine */

/* Global shared variables */
long gsum = 0; /* Global sum */
long nelems_per_thread; /* Number of elements to sum */
sem_t mutex; /* Mutex to protect global sum */
```

```
int main(int argc, char **argv)
{
    long i, nelems, log_nelems, nthreads, myid[MAXTHREADS];
    pthread_t tid[MAXTHREADS];

    /* Get input arguments */
    nthreads = atoi(argv[1]);
    log_nelems = atoi(argv[2]);
    nelems = (1L << log_nelems);
    nelems_per_thread = nelems / nthreads;

    sem_init(&mutex, 0, 1);
    /* Create peer threads and wait for them to finish */
    for (i = 0; i < nthreads; i++) {
        myid[i] = i;
        Pthread_create(&tid[i], NULL, sum_mutex, &myid[i]);
    }

    for (i = 0; i < nthreads; i++)
        Pthread_join(tid[i], NULL);

    /* Check final answer */
    if (gsum != (nelems * (nelems-1))/2)
        printf("Error: result=%ld\n", gsum);

    exit(0);
}
```

```
/* Thread routine for psum-mutex.c */
void *sum_mutex(void *vargp)
{
    long myid = *((long *)vargp); /* Extract thread ID */
    long start = myid * nelems_per_thread; /* Start element index */
    long end = start + nelems_per_thread; /* End element index */
    long i;

    for (i = start; i < end; i++) {
        P(&mutex);
        gsum += i;
        V(&mutex);
    }

    return NULL;
}
```

$1L < N$
: 1을 왼쪽으로
n 비트만큼 이동

$1L < 0$: 00001
 2^0

$1L < 1$: 00010
 2^1
이런 식.

시각
psum-mu
플

psum-mu

psum-mutex performance

8 cores, $N=2^{31}$ 갯수씩 늘려감

Threads (Cores)	1 (1)	2 (2)	4 (4)	8 (8)	16 (8)
psum-mutex (secs)	51	456	790	536	681

↑ 시간

Thread가 늘어났는데 성능은 ↓, 비용은 ↑
사실 이 속도 굉장히 느린 속도.

Next Attempt: psum-array : 각 thread들이 계산한 결과를 각각의 배열 index에 저장


```
/* Thread routine for psum-array.c */
void *sum_array(void *vargp)
{
    long myid = *((long *)vargp); /* Extract thread ID */
    long start = myid * nelems_per_thread; /* Start element index */
    long end = start + nelems_per_thread; /* End element index */
    long i;

    for (i = start; i < end; i++) {
        psum[myid] += i;
    }

    return NULL;
}
```

psum-array.c

→ mutex synchronization 필요 X




Next Attempt: psum-local : thread routine 내에 지역변수 사용 ⇒ register를 쓰자!

```
/* Thread routine for psum-local.c */
void *sum_local(void *vargp)
{
    long myid = *((long *)vargp); /* Extract thread ID */
    long start = myid * nelems_per_thread; /* Start element index */
    long end = start + nelems_per_thread; /* End element index */
    long i, sum = 0;

    for (i = start; i < end; i++) {
        sum += i;
    }

    psum[myid] = sum;
    return NULL;
}
```

psum-local.c



이전에는 indexing을 통한 array element에 대한 memory reference가 계속 일어났었는데, 만약 array가 너무 커서 Main memory 또는 cache가 아니라 Disk에 있었다면?
⇒ 최종적인 sum 결과만 array에 넣기.

Characterizing Parallel Program Performance

p : process cores 개수 / T_k : k 개 Core를 이용해 프로그램을 수행한 running time (k 개의 Thread라고 생각해도 됨)

Speedup $S_p = T_1 / T_p$

→ thread (core) 하나로 수행했을 때보다 Thread (Core) 여러 개로 수행하면 성능이 좋은 것
그래서 T_1 을 T_p 로 나누어 얼마만큼 속도 향상이 이뤄졌는지 판단.

* **Relative Speedup** 언제? T_1 이 parallel version of code (1 core)

Absolute Speedup 언제? T_1 이 sequential version of code (1 core)

↓ Absolute speedup을 기준으로 판단 왜? parallelism의 이점을 파악하기 더 간단.

Efficiency $E_p = S_p / p = T_1 / (p T_p)$

→ Speed up을 p 로 나누는 것 (p는 core의 개수)

→ parallelism으로 인한 overhead 측정시 유용

→ 0~100사이의 percentage로 측정

Performance of psum-local

Threads (t)	1	2	4	8	16
Cores (p)	1	2	4	8	8
Running time (T_p)	1.98	1.14	0.60	0.32	0.33
Speedup (S_p)	1	1.74	3.3	6.19	6
Efficiency (E_p)	100%	87%	82%	77%	75%

$1.14 \div 2 \times 100$ $3.3 \div 4 \times 100$ $6.19 \div 8 \times 100$ $6 \div 8 \times 100$

Memory Consistency

```
int a=1;
int b=100;
```

Thread 1:
Wa a=2
Rb print(b)

Thread 2:
Wb b=200
Ra print(a)

결과가 non deterministic → memory consistency model에 의존

Thread consistency constraints
Wa → Rb
Wb → Ra

Wa → Rb → Wb → Ra 100, 2
 Wa → Wb → Rb → Ra 200, 2
 Wa → Rb → Ra → Rb 2, 200
 Wb → Ra → Wa → Rb 1, 200
 Wb → Wa → Ra → Rb 2, 200
 Wb → Ra → Rb → Ra 200, 2
 100, 1 / 1, 100 불가능

sequential consistency
 쓰레드 내부 순서만 지켜지면
 쓰레드끼리 아무렇게나 섞기 가능
 overall effect consistent with each individual thread
 arbitrary interleaving

Non-Coherent Cache Scenario

write back cache는 값이 바뀌어도 DRAM에 다시 쓰지 X

snoopy caches

Invalid Cannot use value : 이 값 못써! 다른 곳에서 바뀌었어

Shared Readable copy : 읽기만 할 수 있어! 다른 캐시들도 같은 값 갖고 있어!

Exclusive Writable copy : 하나 가지고 있어! 읽기, 쓰기 모두 가능

